

Universidad Central de Venezuela

Facultad de Ciencias
Escuela de Matemáticas
Estadística

Período Lectivo: 2 - 2025

Prof.: Orlan Prato

Proyecto Nro.2
Regresión Lineal y Logística

Autor(es):

Chacón Kimberly
C.I.: V-27.254.966

Guevara Anyeli
C.I.: V-26.989.462

Caracas, Venezuela
9 de marzo de 2026

1. Primera Parte: Implementación de un Modelo de Regresión Lineal Simple

1.1. Comparar los parámetros obtenidos por ambos métodos

Parámetros hallados mediante la fórmula analítica:

Parámetro	Valor
$\hat{\beta}_1$	8846,0391
$\hat{\beta}_0$	27728,0882

Cuadro 1.1.1: Parámetros estimados por MCO

Parámetros hallados mediante descenso del gradiente:

Parámetro	Valor
$\hat{\beta}_1$	8853,0274
$\hat{\beta}_0$	27651,9817

Cuadro 1.1.2: Parámetros estimados por Descenso del Gradiente

1.2. Analizar si los resultados coinciden o presentan diferencias.

Cuadro 1.2.1: Comparación de Métodos de Estimación

Parámetro	MCO	Descenso del Gradiente
$\hat{\beta}_1$ (pendiente)	8,846,0391	8,853,0274
$\hat{\beta}_0$ (punto de corte)	27,728,0882	27,651,9817
ECM	475,308,282,60	475,309,989,00
R^2	0,803381	0,803381

1.3. Graficar los datos originales (YearsExperience vs. Salary).




Figura 1: Análisis exploratorio: dispersión y distribución del salario

1.4. Superponer en el mismo gráfico las rectas obtenidas por ambos métodos.




Figura 2: Rectas ajustadas

1.5. Graficar la evolución de la función de pérdida durante las iteraciones del Descenso del Gradiente.




Figura 3: Función perdida

2. Segunda Parte: Análisis y Clasificación de la Calidad de la Leche mediante Regresión Logística

2.1. Preprocesamiento de Datos

- Carga y exploración inicial del dataset.

Cuadro 2.1.1: Información del Dataset

#	Columna	No. Nulos	Tipo
0	pH	1059	float64
1	Temperature	1059	int64
2	Taste	1059	int64
3	Odor	1059	int64
4	Fat	1059	int64
5	Turbidity	1059	int64
6	Colour	1059	int64
7	Grade	1059	str

- Identificación y tratamiento de valores faltantes o atípicos.

Las columnas Taste, Odor, Fat, turbidity solo tienen valores 1 y 0, pH, Temperature serán Escalados y Colour no se observan valores atípicos, no fue necesario tratamiento de valores atípicos

- Codificación de la variable objetivo.

Se utilizó `LabelEncoder` de `scikit-learn`: para codificar la variable objetivo, con la siguiente codificación por clase:

Clase	Código
high	0
low	1
medium	2

Cuadro 2.1.2: Codificación de la variable objetivo Grade

- Escalado de características numéricas (pH y Temperatura).

Se utilizó `StandardScaler` de `scikit-learn`:

```
from sklearn.preprocessing import StandardScaler
```

para escalar las variables pH y Temperature, generando dos nuevas columnas para ser usadas en la regresión:

```
"pH_escalado", "Temperature_escalado"
```

2.2. Análisis Estadístico Descriptivos

- Cálculo de estadísticas descriptivas:

	count	mean	std	min	10 %	25 %	50 %	75 %	90 %	95 %	max
pH	1059	6.6	1.4	3.0	4.5	6.5	6.7	6.8	8.6	9.0	9.5
Temprature	1059	44.2	10.1	34.0	36.0	38.0	41.0	45.0	55.0	66.0	90.0
Taste	1059	0.5	0.5	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0
Odor	1059	0.4	0.5	0.0	0.0	0.0	0.0	1.0	1.0	1.0	1.0
Fat	1059	0.7	0.5	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0
Turbidity	1059	0.5	0.5	0.0	0.0	0.0	0.0	1.0	1.0	1.0	1.0
Colour	1059	251.8	4.3	240.0	245.0	250.0	255.0	255.0	255.0	255.0	255.0
Grade_encoded	1059	1.1	0.8	0.0	0.0	1.0	1.0	2.0	2.0	2.0	2.0
pH_escalado	1059	0.0	1.0	-2.6	-1.5	-0.1	0.0	0.1	1.4	1.7	2.1
Temprature_escalado	1059	0.0	1.0	-1.0	-0.8	-0.6	-0.3	0.1	1.1	2.2	4.5

- Visualización mediante histogramas y diagramas de caja.





Figura 5: Gráfico de caja de variables numéricas

- Análisis de la distribución de la variable objetivo.






Figura 4: Distribución de variables numéricas

Figura 6: Distribución Variable Objetivo

2.3. Análisis de Correlación

- Cálculo de la matriz de correlación:

	pH	Temperature	Taste	Odor	Fat	Turbidity	Colour	pH_escalado	Temperature_escalado
pH	1.00	0.24	-0.06	-0.08	-0.09	0.05	-0.16	1.00	0.24
Temperature	0.24	1.00	-0.11	-0.05	0.02	0.19	-0.01	0.24	1.00
Taste	-0.06	-0.11	1.00	0.02	0.32	0.06	-0.08	-0.06	-0.11
Odor	-0.08	-0.05	0.02	1.00	0.31	0.46	-0.04	-0.08	-0.05
Fat	-0.09	0.02	0.32	0.31	1.00	0.33	0.11	-0.09	0.02
Turbidity	0.05	0.19	0.06	0.46	0.33	1.00	0.14	0.05	0.19
Colour	-0.16	-0.01	-0.08	-0.04	0.11	0.14	1.00	-0.16	-0.01
pH_escalado	1.00	0.24	-0.06	-0.08	-0.09	0.05	-0.16	1.00	0.24
Temperature_escalado	0.24	1.00	-0.11	-0.05	0.02	0.19	-0.01	0.24	1.00

Cuadro 2.3.1: Matriz de correlación de variables numéricas

■ Visualización mediante mapa de calor:




Figura 7: Mapa de calor

■ Interpretación de las relaciones entre variables:

Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry's standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.

2.4. Implementación del Modelo de Regresión Logística

- División del dataset en entrenamiento (80%) y prueba (20%). Se definieron las variables predictoras X y la variable objetivo y :

```
X = df_milk[["Temperature_escalado", "pH_escalado", "Taste",
             "Odor", "Fat", "Turbidity", "Colour"]]
y = df_milk["Grade_encoded"]
```

El dataset fue dividido en conjuntos de entrenamiento y prueba con una proporción 80/20 mediante `train_test_split` con `random_state=42`:

```
X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size=0.2, random_state=42)
```

■ Entrenamiento del modelo de regresión logística.

Se entrenó un modelo de regresión logística con `max_iter=1000` mediante `scikit-learn`:

```
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)
```

■ Evaluación del modelo utilizando

- Acurracy, Precision, Recall y F1 - score

	Valor
Métrica	
Accuracy	0.8066
Precision	0.8140
Recall	0.8066
F1-Score	0.8080

Cuadro 2.4.1: Métricas de evaluación del modelo de Regresión Logística

- Matriz de confusión




Figura 8: Matriz de confusión

■ Interpretación de los coeficientes del modelo

	Temperature_escalado	pH_escalado	Taste	Odor	Fat	Turbidity	Colour
high	-0.9688	0.2911	0.2944	1.9642	3.4452	0.0309	0.0829
low	2.6199	-0.4237	1.7454	-0.0962	-0.9904	1.8004	0.2341
medium	-1.6511	0.1326	-2.0397	-1.8681	-2.4549	-1.8313	-0.3170

Cuadro 2.4.2: Coeficientes del modelo de Regresión Logística

Clase: Alta (Buena)

Característica	Coeficiente	Interpretación
Fat	+3,45	Característica más importante — la categoría codificada como 1 está fuertemente asociada con la alta calidad en la leche
Odor	+1,96	la categoría codificada como 1 está fuertemente asociada con la alta calidad en la leche
Taste	+0,29	la categoría codificada como 1 tiene un nexo débil con la alta calidad en la leche
pH	+0,29	un pH alto puede tener un leve impacto positivo en la calidad de la leche
Turbidity	+0,03	la categoría codificada como 1 tiene un efecto prácticamente nulo en la alta calidad de la leche
Colour	+0,08	el color puede no tener impacto en la calidad de la leche
Temperature	−0,97	una temperatura alta puede tener un impacto negativo en la calidad de la leche

Clase: Baja (Mala)

Característica	Coefficiente	Interpretación
Temperature	+2,62	Característica importante — altas temperaturas indican una mala calidad en la leche
Turbidity	+1,80	la categoría codificada como 1 está fuertemente asociada con la mala calidad en la leche
Taste	+1,75	la categoría codificada como 1 está fuertemente asociada con la mala calidad en la leche
Odor	−0,10	efecto prácticamente nulo
Fat	−0,99	la categoría codificada como 1 está fuertemente asociada con poca probabilidad de mala calidad en la leche
Colour	+0,23	un fuerte color puede tener un impacto leve en la mala calidad de la leche
pH	−0,42	un pH bajo puede estar levemente asociado a la mala calidad en la leche

Clase: Media (Moderada)

Característica	Coefficiente	Interpretación
Taste	−2,04	la categoría codificada como 1 está fuertemente asociada en la baja probabilidad de calidad media en la leche
Fat	−2,45	la categoría codificada como 1 está fuertemente asociada en la baja probabilidad de calidad media en la leche
Odor	−1,87	la categoría codificada como 1 está fuertemente asociada en la baja probabilidad de calidad media en la leche
Turbidity	−1,83	la categoría codificada como 1 está fuertemente asociada en la baja probabilidad de calidad media en la leche
Temperature	−1,65	la alta temperatura tiene un impacto negativo en la probabilidad de calidad media en la leche
Colour	−0,32	el color fuerte puede tener un impacto leve en la baja probabilidad de calidad media en la leche
pH	+0,13	el pH puede no tener impacto en la probabilidad de calidad media en la leche

Resumen

- **Fat y Odor** son las características principales para identificar leche de buena calidad.
 - **Temperature y Turbidity** son las señales más fuertes de mala calidad en la leche — temperatura tibia y categoría 1 en la turbidez.
 - **Calidad media** está constantemente vinculada a la ausencia del valor 1 en las categorías Taste, Fat, Odor y Turbidity.
- Discusión de resultados y posibles mejoras

Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry's standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.