

Universidad Central de Venezuela

Facultad de Ciencias
Escuela de Matemáticas
Estadística

Período Lectivo: 2 - 2025

Prof.: Orlan Prato

Proyecto Nro.2

Regresión Lineal y Logística

Autor(es):

Chacón Kimberly
C.I.: V-27.254.966

Guevara Anyeli
C.I.: V-26.989.462

Caracas, Venezuela
11 de marzo de 2026

Introducción

El análisis de datos y el aprendizaje supervisado se han consolidado como pilares fundamentales para la interpretación de fenómenos complejos en diversos sectores. El presente proyecto tiene como objetivo integrar los fundamentos teóricos de la estadística con la implementación computacional, abordando dos de los algoritmos más relevantes en la ciencia de datos: la **Regresión Lineal Simple** y la **Regresión Logística Multiclase**.

La primera parte del estudio se enfoca en el análisis del conjunto de datos *Salary*, donde se busca modelar la relación entre los años de experiencia y el salario percibido. A través de este ítem, se exploran las diferencias que puedan existir entre la solución analítica (Forma Teórica) y la optimización numérica mediante el algoritmo de **Descenso del Gradiente**, permitiendo validar la convergencia de parámetros en un modelo de predicción de valores continuos.

Por otro lado, la segunda fase se orienta a la clasificación de la calidad láctea mediante un modelo logístico. A diferencia de la estimación de valores numéricos, este apartado aborda un problema de categorización basado en siete variables independientes. El desarrollo de esta etapa incluye un riguroso proceso de preprocesamiento, escalado de características y evaluación mediante métricas de desempeño como el *Accuracy* y la matriz de confusión.

A través de este enfoque dual, el proyecto no solo busca obtener resultados numéricos precisos, sino también desarrollar una capacidad crítica para interpretar cómo las variables del mundo real, ya sea el tiempo de carrera profesional o el pH de la leche, pueden ser modeladas matemáticamente para generar predicciones confiables y útiles en la toma de decisiones estratégicas.

1. Primera Parte: Implementación de un Modelo de Regresión Lineal Simple

1.1. Comparar los parámetros obtenidos por ambos métodos

Parámetros hallados mediante la fórmula analítica:

Parámetro	Valor
$\hat{\beta}_1$	8846,0391
$\hat{\beta}_0$	27728,0882

Cuadro 1.1.1: Parámetros estimados por MCO

Parámetros hallados mediante descenso del gradiente:

Parámetro	Valor
$\hat{\beta}_1$	8853,0274
$\hat{\beta}_0$	27651,9817

Cuadro 1.1.2: Parámetros estimados por Descenso del Gradiente

Conclusion: Como se puede apreciar en los Cuadros 1.1.1 y 1.1.2, al contrastar los resultados obtenidos mediante el método de Mínimos Cuadrados Ordinarios (MCO) y el algoritmo de Descenso del Gradiente, se observan valores similares en los parámetros calculados.

Específicamente, se halló una diferencia numérica de apenas 6,9883 para el coeficiente de la pendiente ($\hat{\beta}_1$) y de 76,1065 para el intercepto ($\hat{\beta}_0$). Esta proximidad en los valores de $\hat{\beta}_1$ y $\hat{\beta}_0$ indica que ambos métodos, a pesar de seguir procedimientos de optimización distintos, tienden a coincidir en la definición de la recta de regresión sobre la data empleada, validando así la precisión de la implementación numérica del gradiente frente a la solución analítica.

1.2. Analizar si los resultados coinciden o presentan diferencias.

Cuadro 1.2.1: Comparación de Métodos de Estimación

Parámetro	MCO	Descenso del Gradiente
$\hat{\beta}_1$ (pendiente)	8846,0391	8853,0274
$\hat{\beta}_0$ (punto de corte)	27728,0882	27651,9817
ECM	475308282,60	475309989,00
R^2	0,803381	0,803381

Conclusión: Como se puede observar en el **Cuadro 1.2.1**, al contrastar los parámetros obtenidos por ambos métodos, se evidencia que los valores de $\hat{\beta}_1$ y $\hat{\beta}_0$ son muy similares entre sí. En cuanto al Error Cuadrático Medio (ECM), los resultados coinciden

significativamente hasta el quinto término, ya que el método analítico arroja un valor de 475308282,60 y el método de Descenso del Gradiente resulta en 475309989,00.

Debido a que el ECM mide promedios de errores, esta diferencia resulta marginal en términos de magnitud relativa, pudiendo establecerse la siguiente aproximación:

$$475308282,60 \approx 47531 \times 10^4 \approx 475309989,00 \quad (1)$$

Por ende, nos encontramos en el mismo escenario de convergencia observado en los parámetros $\hat{\beta}_1$ y $\hat{\beta}_0$. Finalmente, el coeficiente de determinación (R^2) es idéntico para ambos métodos (0,803381); dado que este indicador mide qué tan bien se ajusta el modelo a los datos, podemos concluir que ambos modelos se aproximan a la realidad de la misma manera.

En virtud de lo anterior, se determina que los resultados coinciden plenamente entre sí y que no existen diferencias sustanciales entre la aplicación del método analítico y el algoritmo de optimización numérica.

1.3. Graficar los datos originales (YearsExperience vs. Salary).




Figura 1: Análisis exploratorio: dispersión y distribución del salario

1.4. Superponer en el mismo gráfico las rectas obtenidas por ambos métodos.




Figura 2: Rectas ajustadas

1.5. Graficar la evolución de la función de pérdida durante las iteraciones del Descenso del Gradiente.




Figura 3: Función perdida

Interpretación: aquí podemos observar cómo el modelo va aprendiendo en base a la cantidad de pasos con un cambio grande entre las primeras 200 iteraciones y estabilizándose desde aproximadamente las 300 en adelante.

2. Segunda Parte: Análisis y Clasificación de la Calidad de la Leche mediante Regresión Logística

2.1. Preprocesamiento de Datos

- Carga y exploración inicial del dataset.

Cuadro 2.1.1: Información del Dataset

#	Columna	No. Nulos	Tipo
0	pH	1059	float64
1	Temperature	1059	int64
2	Taste	1059	int64
3	Odor	1059	int64
4	Fat	1059	int64
5	Turbidity	1059	int64
6	Colour	1059	int64
7	Grade	1059	str

- Identificación y tratamiento de valores faltantes o atípicos. En este caso, se puede observar que con un valor total de 1059 datos proporcionados, no hay valores faltantes dentro del DataFrame (resumen observable en el cuadro 2.1.1). En cuanto a los valores atípicos, se decidió dejar como tratamiento el 'Escalado de características' solicitado en el ultimo requerimiento de este paso 1; esto debido a que los valores atípicos estan dentro del rango posible (como en el caso del PH) o son muy pequeños en cantidad a comparación de la cantidad de datos proporcionados en el DataFrame; en este orden de ideas, con el 'Escalado' mitigamos el impacto numérico que estos puedan tener en la data.
- Codificación de la variable objetivo.

Se utilizó `LabelEncoder` de `scikit-learn`: para codificar la variable objetivo, con la siguiente codificación por clase:

Clase	Código
high	0
low	1
medium	2

Cuadro 2.1.2: Codificación de la variable objetivo Grade

- Escalado de características numéricas (pH y Temperatura).

Se utilizó `StandardScaler` de `scikit-learn`:

```
from sklearn.preprocessing import StandardScaler
```

para escalar las variables pH y Temperature, generando dos nuevas columnas para ser usadas en la regresión:

"pH_escalado", "Temperature_escalado"

2.2. Análisis Estadístico Descriptivos

- Cálculo de estadísticas descriptivas:

	count	mean	std	min	10 %	25 %	50 %	75 %	90 %	95 %	max
pH	1059	6.6	1.4	3.0	4.5	6.5	6.7	6.8	8.6	9.0	9.5
Temperature	1059	44.2	10.1	34.0	36.0	38.0	41.0	45.0	55.0	66.0	90.0
Taste	1059	0.5	0.5	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0
Odor	1059	0.4	0.5	0.0	0.0	0.0	0.0	1.0	1.0	1.0	1.0
Fat	1059	0.7	0.5	0.0	0.0	0.0	1.0	1.0	1.0	1.0	1.0
Turbidity	1059	0.5	0.5	0.0	0.0	0.0	0.0	1.0	1.0	1.0	1.0
Colour	1059	251.8	4.3	240.0	245.0	250.0	255.0	255.0	255.0	255.0	255.0
Grade_encoded	1059	1.1	0.8	0.0	0.0	1.0	1.0	2.0	2.0	2.0	2.0
pH_escalado	1059	0.0	1.0	-2.6	-1.5	-0.1	0.0	0.1	1.4	1.7	2.1
Temperature_escalado	1059	0.0	1.0	-1.0	-0.8	-0.6	-0.3	0.1	1.1	2.2	4.5

- Visualización mediante histogramas y diagramas de caja.




Figura 5: Gráfico de caja de variables numéricas

- Análisis de la distribución de la variable objetivo.




Figura 4: Distribución de variables numéricas




Figura 6: Distribución Variable Objetivo

Interpretación: Se realizó un gráfico descriptivo con cada variable objetivo cuyo fin fue el de determinar la distribución de los datos en las categorías *High*, *Low* y *Medium* mediante la variable '*Grade*'. A partir de las visualizaciones, se observó que la mayor parte de la

muestra se concentra en la categoría de baja calidad (*Low*), seguida en frecuencia por la categoría media (*Medium*). Por el contrario, la categoría de alta calidad (*High*) resultó ser la menos frecuente, presentando casi la mitad de la frecuencia observada en la clase predominante (*Low*). Este comportamiento evidencia que las clases se encuentran desbalanceadas. En consecuencia, esta disparidad en la representatividad de los datos afectará la capacidad predictiva del modelo de regresión logística, particularmente en la precisión de la clase *High*, como se analizará posteriormente en los resultados de desempeño.

2.3. Análisis de Correlación

- Cálculo de la matriz de correlación:

	pH	Temperature	Taste	Odor	Fat	Turbidity	Colour	pH_escalado	Temperature_escalado
pH	1.00	0.24	-0.06	-0.08	-0.09	0.05	-0.16	1.00	0.24
Temperature	0.24	1.00	-0.11	-0.05	0.02	0.19	-0.01	0.24	1.00
Taste	-0.06	-0.11	1.00	0.02	0.32	0.06	-0.08	-0.06	-0.11
Odor	-0.08	-0.05	0.02	1.00	0.31	0.46	-0.04	-0.08	-0.05
Fat	-0.09	0.02	0.32	0.31	1.00	0.33	0.11	-0.09	0.02
Turbidity	0.05	0.19	0.06	0.46	0.33	1.00	0.14	0.05	0.19
Colour	-0.16	-0.01	-0.08	-0.04	0.11	0.14	1.00	-0.16	-0.01
pH_escalado	1.00	0.24	-0.06	-0.08	-0.09	0.05	-0.16	1.00	0.24
Temperature_escalado	0.24	1.00	-0.11	-0.05	0.02	0.19	-0.01	0.24	1.00

Cuadro 2.3.1: Matriz de correlación de variables numéricas

- Visualización mediante mapa de calor:




Figura 7: Mapa de calor

- Interpretación de las relaciones entre variables:

Dado que el mapa de calor (Figura 7) representa los mismos valores que la matriz de correlación, el análisis se centra en aquellos coeficientes que se sitúan en el rango $[0, 8; 1, 0]$, donde se localizan las relaciones más fuertes. Al observar la matriz, se evidencia que los únicos pares de variables que alcanzan el nivel máximo de correlación (1,0), excluyendo la diagonal principal, son *pH* con *pH_escalado* y *Temperature* con *Temperature_escalado*.

Debido a que *Temperature_escalado* y *pH_escalado* son transformaciones directas de las variables originales *Temperature* y *pH* (las cuales recibieron tratamiento de escalado en la Fase 1 al ser las únicas variables no binarias), es lógico que presenten una relación lineal perfecta. Esta correspondencia directa asegura que la información original se preserve íntegramente tras la transformación, eliminando disparidades de magnitud y mejorando significativamente la eficiencia del algoritmo durante el entrenamiento del modelo logístico.

Por otro lado, también se puede observar una tendencia compartida entre el Olor y la Turbidez; esto nos indica que la turbidez presente en la leche puede afectar un poco su olor y viceversa.

2.4. Implementación del Modelo de Regresión Logística

- División del dataset en entrenamiento (80 %) y prueba (20 %). Se definió el conjunto de variables predictoras *X* y la variable objetivo *y*:

```
X = df_milk[["Temperature_escalado", "pH_escalado", "Taste",  
            "Odor", "Fat", "Turbidity", "Colour"]]  
y = df_milk["Grade_encoded"]
```

El dataset fue dividido en conjuntos de entrenamiento y prueba con una proporción 80/20 mediante `train_test_split` con `random_state=42`:

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
                                                    test_size=0.2, random_state=42)
```

- Entrenamiento del modelo de regresión logística.

Se entrenó un modelo de regresión logística con `max_iter=1000` mediante `scikit-learn`:

```
model = LogisticRegression(max_iter=1000)  
model.fit(X_train, y_train)
```

- Evaluación del modelo utilizando

- Accuracy, Precision, Recall y F1 - score

	Valor
Métrica	
Accuracy	0.8538
Precision	0.8660
Recall	0.8538
F1-Score	0.8567

Cuadro 2.4.1: Métricas de evaluación del modelo de Regresión Logística

Interpretación: tras la evaluación del modelo de regresión logística multiclase, se obtuvieron métricas de desempeño consistentes, con un *Accuracy* de 0,8537 y un *F1-Score* de 0,8566. La *Precision* de 0,8660 indica una alta confiabilidad en las predicciones positivas, minimizando la incidencia de falsos positivos en la clasificación de la calidad de la leche.

Por otro lado, el *Recall* de 0,8537 demuestra una capacidad robusta del algoritmo para identificar correctamente las clases dentro del conjunto de prueba. Dado que todas las métricas se encuentran en un rango similar por encima del 0,85, se concluye que el modelo presenta un equilibrio óptimo entre sensibilidad y especificidad, siendo capaz de generalizar los patrones registrados en el Data Frame proporcionado a pesar del desbalance de clases identificado previamente.

- Matriz de confusión




Figura 8: Matriz de confusión

Interpretación: Al analizar la matriz de confusión, se observa un desempeño

sobresaliente en la clasificación de las categorías *Medium* y *Low*. El modelo logra predecir de manera casi exacta la pertenencia de las muestras en estas clases, incurriendo en solo 5 y 8 clasificaciones erróneas, respectivamente. Este alto nivel de acierto valida la eficacia de los coeficientes calculados para las características predominantes en el dataset.

Por el contrario, al evaluar los resultados para la leche de calidad *High*, se confirma la hipótesis planteada anteriormente: la escasez de muestras en esta categoría (desbalance de clases) afecta la precisión del algoritmo, derivando en la clasificación incorrecta de 18 muestras. No obstante, al contrastar estos hallazgos con las métricas globales presentadas en el **Cuadro 2.4.1**, se ratifica que el modelo mantiene una robustez general notable, logrando un equilibrio predictivo eficiente a pesar de las limitaciones en la representatividad de la clase *High*.

■ Interpretación de los coeficientes del modelo

	Temperature_escalado	pH_escalado	Taste	Odor	Fat	Turbidity	Colour
high	-0.8754	0.2595	0.2878	1.9378	3.3901	0.0162	0.0892
low	2.7176	-0.4290	1.8809	0.0061	-0.9197	1.8118	0.2506
medium	-1.8422	0.1695	-2.1687	-1.9439	-2.4703	-1.8280	-0.3398

Cuadro 2.4.2: Coeficientes del modelo de Regresión Logística

Clase: 'High' (Buena)

Característica	Coefficiente	Interpretación
Fat	+3,45	Un buen contenido de grasa tiene una alta influencia con la alta calidad en la leche
Odor	+1,96	Un buen olor está fuertemente asociada con la alta calidad en la leche
Taste	+0,29	El tener sabor perceptible tiene un nexo débil con la alta calidad en la leche
pH	+0,29	Un pH alto puede tener un leve impacto positivo en la calidad de la leche
Turbidity	+0,03	Se observa que tener turbidez tiene un efecto prácticamente nulo en la alta calidad de la leche
Colour	+0,08	El color puede no tener impacto en la calidad de la leche
Temperature	-0,97	Una temperatura alta puede tener un impacto negativo en la calidad de la leche

Clase: Low (Mala)

Característica	Coeficiente	Interpretación
Temperature	+2,62	Altas temperaturas indican una mala calidad en la leche
Turbidity	+1,80	La presencia de Turbidez está fuertemente asociada con la mala calidad en la leche
Taste	+1,75	Un sabor perceptible está asociado con la mala calidad en la leche
Odor	−0,10	El buen olor esta poco presente en la leche de calidad baja siendo casi nulo.
Fat	−0,99	Tener una buena presencia de grasa está fuertemente asociada con poca probabilidad de mala calidad en la leche
Colour	+0,23	un fuerte color puede tener un impacto leve en la mala calidad de la leche
pH	−0,42	un pH bajo puede estar levemente asociado a la mala calidad en la leche

Clase: Medium (Moderada)

Característica	Coeficiente	Interpretación
Taste	−2,04	Un buen sabor está fuertemente asociada en la baja probabilidad de calidad media en la leche
Fat	−2,45	Una buena presencia de grasa está fuertemente asociada en la baja probabilidad de calidad media en la leche
Odor	−1,87	El buen olor está fuertemente asociada en la baja probabilidad de calidad media en la leche
Turbidity	−1,83	La presencia de turbidez está fuertemente asociada en la baja probabilidad de calidad media en la leche
Temperature	−1,65	la alta temperatura tiene un impacto negativo en la probabilidad de calidad media en la leche
Colour	−0,32	el color fuerte puede tener un impacto leve en la baja probabilidad de calidad media en la leche
pH	+0,13	el pH puede no tener impacto en la probabilidad de calidad media en la leche

Resumen

- **Fat y Odor** son las características principales para identificar leche de buena calidad.
 - **Temperature y Turbidity** son las señales más fuertes de mala calidad en la leche — temperatura tibia y categoría 1 en la turbidez.
 - **Calidad media** está constantemente vinculada a la ausencia del valor 1 en las categorías Taste, Fat, Odor y Turbidity.
- Discusión de resultados y posibles mejoras

Tras el análisis exhaustivo del desempeño del modelo y la naturaleza de los datos suministrados, se presentan las siguientes recomendaciones estratégicas para futuras iteraciones del proyecto:

1. **Balanceo de la Muestra:** Se sugiere a la empresa implementar protocolos de recolección que garanticen un equilibrio en la representatividad de las categorías. Un conjunto de datos con una distribución más equitativa entre las clases *High*, *Medium* y *Low* permitiría reducir el sesgo hacia la clase mayoritaria y mejorar significativamente la sensibilidad del modelo de regresión en la identificación de leche de alta calidad.
2. **Control de Calidad en el Registro:** Si bien la incidencia de valores atípicos (*outliers*) fue reducida, se recomienda optimizar los procesos de captura de datos en origen. Una mayor precisión y consistencia en el registro de las variables fisicoquímicas minimizaría el ruido estadístico, facilitando la generación de un modelo más depurado, con una frontera de decisión más clara y apegada a la realidad operativa de la planta.
3. **Optimización de Variables Críticas:** Basándose en la magnitud de los coeficientes del modelo, se proponen las siguientes pautas operativas para maximizar la calidad del producto:
 - **Potencial de Hidrógeno (pH):** Se observa que mantener niveles de pH controlados hacia el rango superior del estándar favorece la clasificación en categorías de alta calidad.
 - **Control Térmico:** La temperatura es un factor crítico; las lecturas elevadas presentan una correlación negativa con la calidad, por lo que se debe extremar el cuidado en la cadena de frío para evitar degradaciones significativas.
 - **Propiedades Organolépticas (Sabor y Olor):** Aunque el impacto del sabor es moderado, una intensidad excesiva o atípica puede penalizar la clasificación. Por el contrario, la preservación de un olor característico y agradable potencia significativamente la probabilidad de obtener una calificación *High*.
 - **Contenido Graso (*Fat*):** Esta característica se identifica como el factor más determinante para la leche de alta calidad. El modelo asigna un peso significativo a esta variable, por lo que optimizar los niveles de grasa es la ruta más directa para mejorar la calificación global del producto.

- **Claridad y Turbidez:** Se debe minimizar la turbidez en las muestras, ya que su presencia actúa como un predictor crítico de baja calidad dentro de las fronteras de decisión del algoritmo.
- **Atributos Visuales (*Colour*):** El color es un indicador de pureza fundamental. Los resultados sugieren que tonalidades excesivamente fuertes o desviadas del blanco estándar están altamente correlacionadas con una clasificación de mala calidad, por lo que se requiere un control estricto de la apariencia visual.

Estas mejoras no solo incrementarían las métricas de *Accuracy* y *F1-Score* obtenidas (0,8537 y 0,8566 respectivamente), sino que dotarían a la organización de una herramienta de auditoría de calidad mucho más robusta y confiable para la toma de decisiones.

Conclusiones

El desarrollo de este proyecto permitió consolidar de manera práctica los fundamentos de la regresión lineal y logística, aplicando tanto soluciones analíticas como algoritmos de optimización numérica sobre conjuntos de datos reales.

Eficacia del Ajuste Lineal (Ítem 1: Salary Dataset)

En la primera fase, la implementación del modelo de regresión lineal simple para predecir el salario en función de los años de experiencia validó la precisión del **Descenso del Gradiente** frente a la **Forma Teórica**. La convergencia de los parámetros con una diferencia marginal de 6,9883 en la pendiente y 76,1065 en el sesgo demuestra que, el algoritmo iterativo es capaz de alcanzar la solución óptima global de la función de pérdida. El ajuste obtenido, con un R^2 de 0,803381, ratifica que la experiencia es un predictor robusto y linealmente relacionado con la estructura salarial analizada.

Robustez en la Clasificación (Ítem 2: Calidad de la Leche)

En la segunda fase, el uso de regresión logística multiclase para categorizar la calidad de la leche demostró la importancia crítica del preprocesamiento y el análisis estadístico descriptivo. Las conclusiones clave de esta etapa incluyen:

- **Impacto de las Variables:** El escalado de pH y Temperatura fue determinante para estabilizar el modelo. El análisis de coeficientes identificó al contenido graso y al pH como los promotores de calidad más significativos, mientras que la turbidez y las altas temperaturas actúan como indicadores de degradación.
- **Desempeño del Modelo:** Se alcanzó un *Accuracy* de 0,8537 y un *F1-Score* de 0,8566. Aunque el desbalance de clases afectó la precisión en la categoría *High* (18 clasificaciones erróneas), el modelo mostró una fiabilidad sobresaliente para las clases *Low* y *Medium*.

En conclusión, el proyecto demuestra que mientras la regresión lineal es ideal para estimar valores continuos (salarios), la regresión logística, apoyada en una correcta interpretación de la matriz de confusión y métricas de precisión, constituye una herramienta poderosa para la clasificación técnica de productos. La integración de herramientas computacionales con el análisis estadístico permitió transformar datos brutos en información estratégica para la toma de decisiones en entornos industriales y corporativos.

Todo el proceso detallado de estudio que fue realizado para llegar a las conclusiones presentadas puede ser visualizado a través del siguiente enlace https://github.com/kimachd/ESTADISTICA_sem_II_2025/tree/main/proyecto_2/